

DuocUC® INFORMÁTICA Y TELECOMUNICACIONES

Transformaciones espaciales y normalización de datos

TLY1102

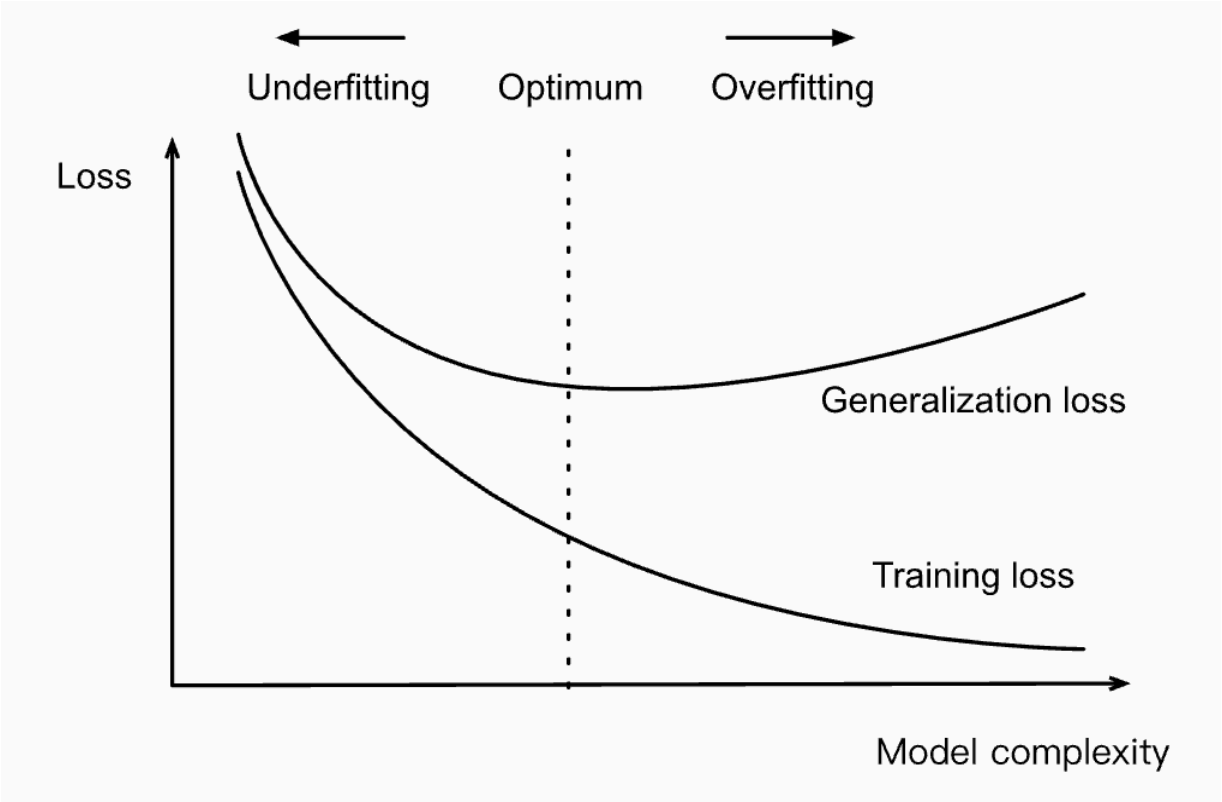
FORMAMOS PERONAS PARA UNA SOCIEDAD MEJOR



01

Introducción

• OVERFITTING



¿Qué ocurre cuando un modelo aprende demasiado?

- El desempeño sobre los **datos de entrenamiento** sigue mejorando.
- El desempeño sobre los **datos de validación** deja de mejorar e incluso empeora.
- El modelo comienza a **memorizar ejemplos específicos** en lugar de aprender patrones generales.

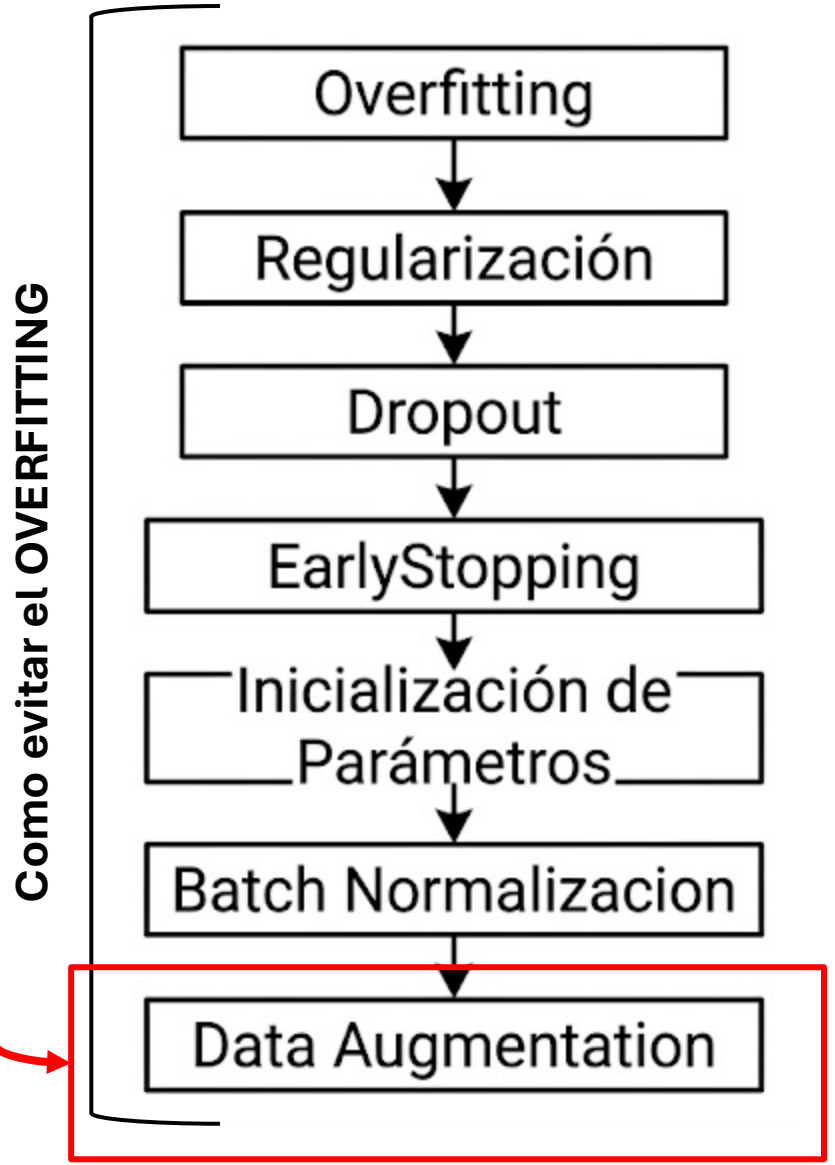
El objetivo de una red neuronal es obtener el balance entre optimización y generalización de los datos que nunca han visto.

• OVERFITTING

Causas del sobreajuste:

- **Datos de entrenamiento insuficientes.**
- **Falta de diversidad espacial o temporal:** El modelo puede memorizar el contexto de una foto, pero no reconocerá los patrones.
- **Desequilibrio de clases:** Si una categoría tiene muchas menos muestras que el resto, el modelo no aprenderá a reconocerla.
- **Exceso de sensibilidad a pequeñas variaciones:** Un modelo puede fallar si la entrada está ligeramente desplazada.

¿Cómo podemos enseñar al modelo a reconocer un objeto en muchas condiciones diferentes sin tener que recopilar miles de imágenes nuevas?





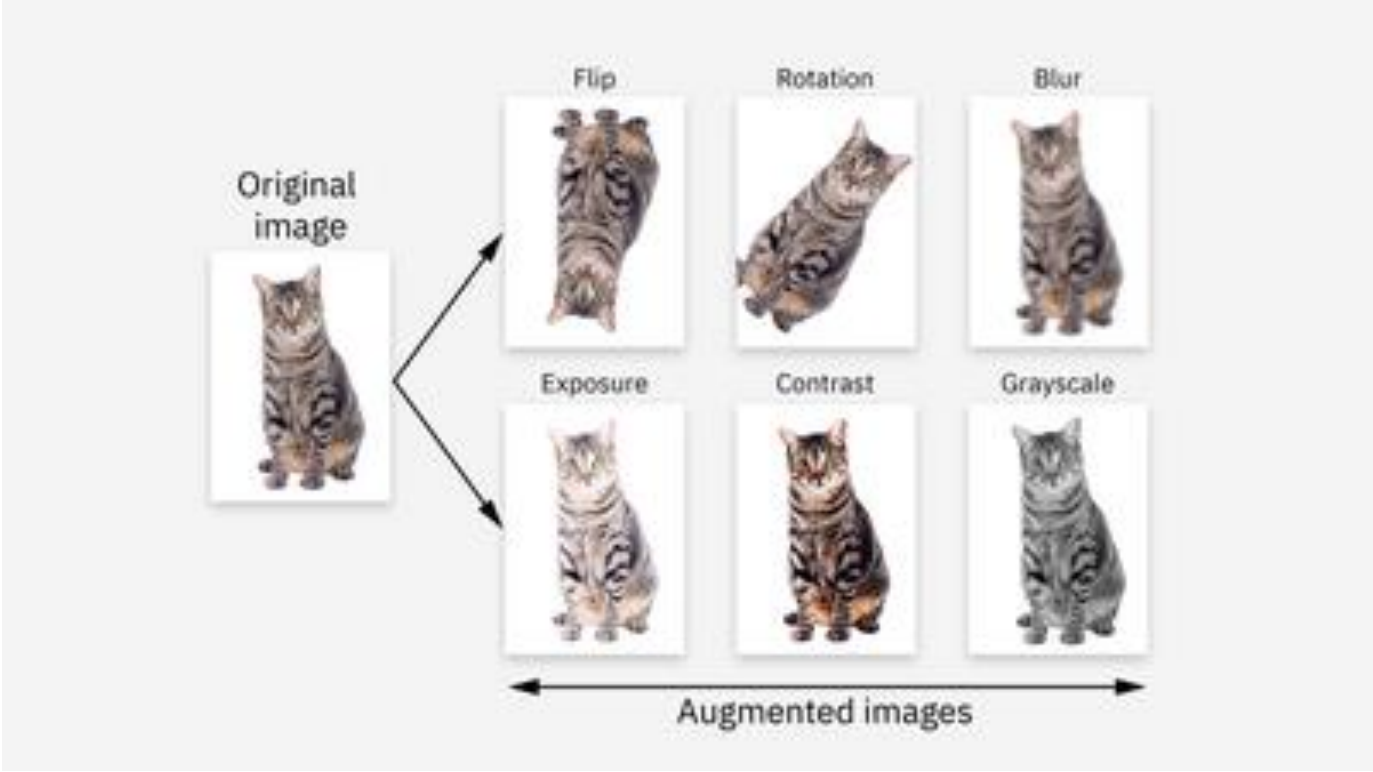
02

Data Augmentation

Data Augmentation

El **aumento de datos** es una técnica que **consiste en aumentar artificialmente el conjunto de entrenamiento** creando copias modificadas de un conjunto de datos **utilizando los datos existentes**.

Incluye realizar pequeños cambios en el conjunto de datos o utilizar el aprendizaje profundo para generar nuevos puntos de datos.

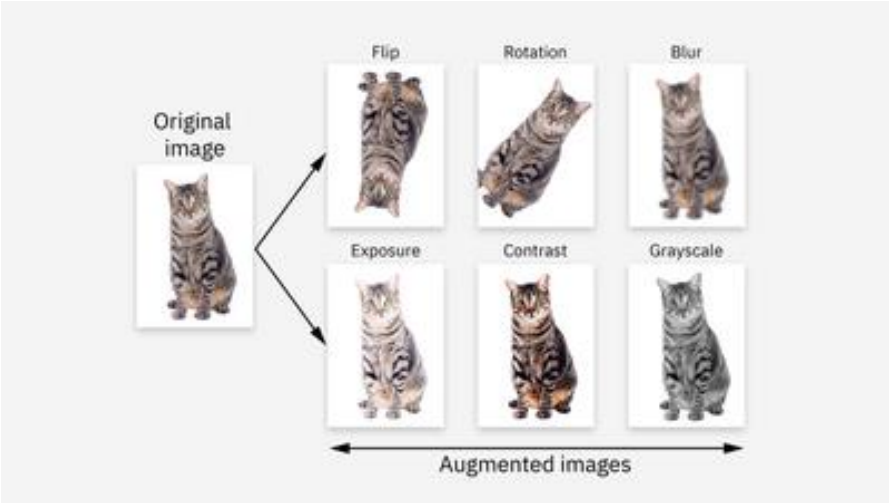


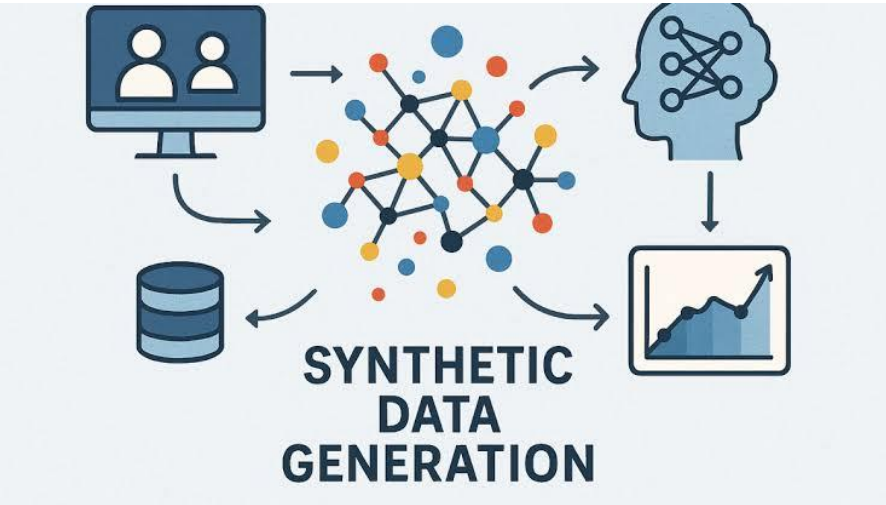
Al observar múltiples versiones del mismo objeto, la red aprende características invariantes (forma, textura, estructura) en lugar de memorizar una única imagen.

Datos aumentados frente a datos sintéticos

Los **datos aumentados** se **obtienen a partir de los datos originales** con algunos cambios menores, pero **conservando su misma etiqueta**. En el caso del aumento de imágenes, realizamos transformaciones geométricas y del espacio de color (flipping, cambio de tamaño, recorte, brillo, contraste) para aumentar el tamaño y la diversidad del conjunto de entrenamiento.

Los **datos sintéticos** se **generan artificialmente sin utilizar el conjunto de datos original**. A menudo **se utilizan redes neuronales profundas** (DNN) **y redes generativas adversativas** (GAN) para generar datos sintéticos.





Nota: Las técnicas de aumento no se limitan a las imágenes. También puedes aumentar audio, vídeo, texto y otros tipos de datos.

• ¿Cuándo debes utilizar el aumento de datos?

1. Para que los modelos no se **sobreajusten**.
2. Cuando el **conjunto de entrenamiento inicial es demasiado pequeño**.
3. Para **mejorar la exactitud del modelo**.
4. Para **reducir el coste operativo del etiquetado** y **limpieza del conjunto de datos brutos**.

Limitaciones del aumento de datos

Los **sesgos del conjunto de datos original persisten en los datos aumentados**.

La garantía de calidad para **el aumento de datos es cara**.

Encontrar un enfoque eficaz de aumento de datos **puede ser todo un reto**.

• Tipos de aumento de datos en imágenes

1. Transformaciones geométricas

- **Flip**: Los volteos horizontales o verticales simulan perspectivas reflejadas.
- **Rotación**: Gira las imágenes en ángulos pequeños (p. ej., de -15° a +15°).
- **Traslación**: Desplaza la imagen a lo largo de los ejes X e Y.
- **Escalado**: Acerca o aleja la imagen, simulando diferentes distancias.
- **Recorte**: Los recortes aleatorios obligan a los modelos a centrarse en diferentes partes del objeto.

2. Aumento del espacio de color: Estas técnicas son especialmente útiles para la detección o clasificación de objetos en condiciones de iluminación variables.

- **Brillo**: Ajustar el brillo simula diferentes condiciones de iluminación.
- **Contraste y saturación**: Enfatiza o suaviza la intensidad del color.
- **Cambio de tono**: Altera ligeramente el tono del color.

3. Inyección de ruido

- El **ruido gaussiano** simula errores del sensor o condiciones de poca luz.
- El **desenfoque** (p. ej., gaussiano o de movimiento) imita el movimiento de la cámara o la falta de enfoque.
- **Borrado aleatorio** (o recorte): Enmascara parte de la imagen para simular una oclusión.

• Aumento de datos en contextos diferentes a imagen

Aumento de datos de audio

1. **Inyección de ruido**: añade ruido gaussiano o aleatorio al conjunto de datos de audio para mejorar el rendimiento del modelo.

2. **Desplazamiento**: desplaza el audio a la izquierda (avance rápido) o a la derecha con segundos aleatorios.

3. **Cambio de velocidad**: estira las series temporales con una velocidad fija.

4. **Cambio de tono**: cambia aleatoriamente el tono del audio.

Aumento de datos de texto

1. **Transposición de palabras o frases**: cambia aleatoriamente la posición de una palabra o frase.

2. **Sustitución de palabras**: sustituye palabras por sinónimos.

3. **Manipulación del árbol de sintaxis**: parafrasea la frase utilizando la misma palabra.

4. **Inserción aleatoria de palabras**: inserta palabras aleatoriamente.

5. **Eliminación aleatoria de palabras**: elimina palabras aleatoriamente.



03

Aplicación

Preprocesamiento

- Debemos diferenciar el preprocesamiento con el aumento de datos.
- **El preprocesamiento contempla la etapa de escalar la imagen a su tamaño original y normalizarla**.
- Este proceso no se considera como aumento de datos y **debe realizarse siempre**.

Normalizar consiste en **transformar los datos a una escala común** antes del entrenamiento.

En imágenes normalmente: `pixel / 255`

- Mejora la estabilidad del entrenamiento
- Acelera el descenso del gradiente
- Evita que algunas variables dominen sobre otras

Implementación en Código

```
IMG_SIZE=180
resize_and_rescale=keras.Sequential([
        layer.Resizing(IMG_SIZE,IMG_SIZE),
        layers.Rescaling(1./255)
])
result=resize_and_rescale(image)
plt.axis('off')
plt.imshow(result);
```

Aumento de datos con Keras Sequential

Añadir directamente a la capa del modelo

El primer método consiste en añadir directamente las capas de aumento al modelo.

```
model = keras.Sequential([
  # Add the preprocessing layers you
created earlier.
  resize_and_rescale,
  data_augmentation,
  # Add the model layers
  layers.Conv2D(16, 3, padding='same',
activation='relu'),
  layers.MaxPooling2D(),
  layers.Flatten(),
  layers.Dense(128, activation='relu'),
  layers.Dense(64, activation='relu'),
  layers.Dense(1,activation='sigmoid')
])
```

El segundo método consiste en aplicar el aumento de datos a todo el conjunto de entrenamiento mediante Dataset.map.

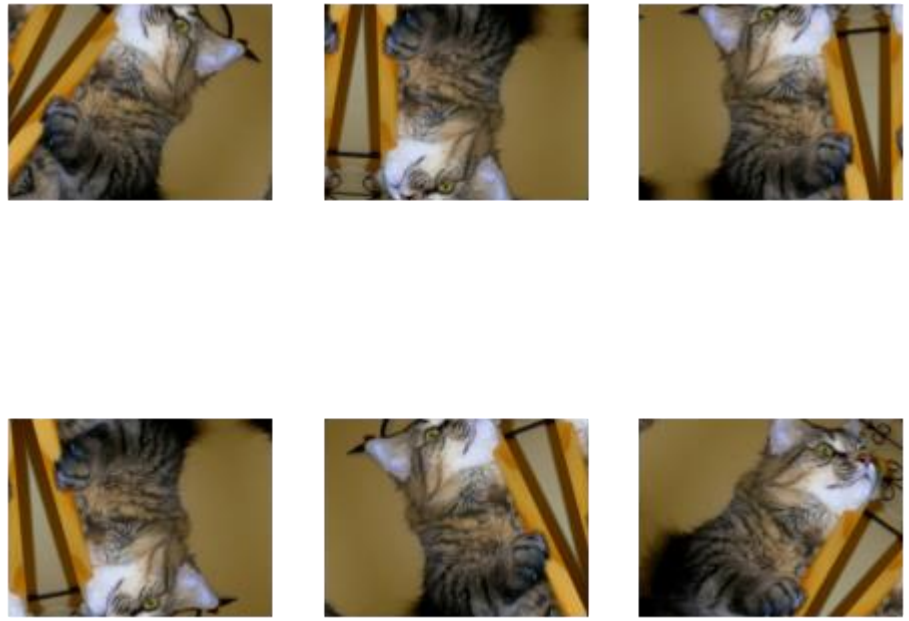
```
aug_ds = train_ds.map(lambda x, y:
(data_augmentation(x,
training=True), y))
```

Aumento de datos con Keras Sequential

Rotación y flip aleatorios

```
data_augmentation = keras.Sequential([
  layers.RandomFlip("horizontal_and_vertical"),
  layers.RandomRotation(0.4),
])
```

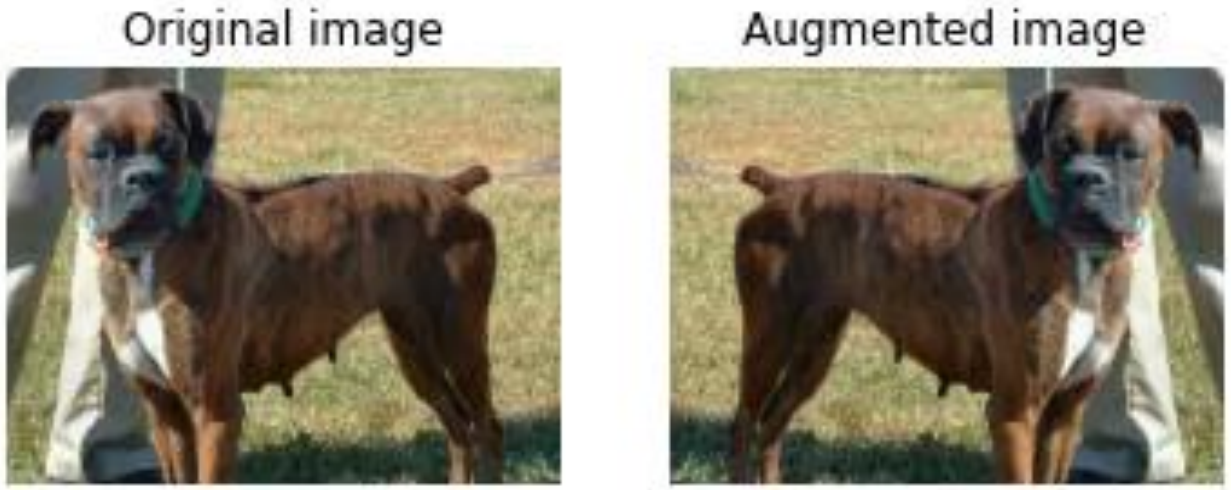
```
plt.figure(figsize=(8, 7))
for i in range(6):
  augmented_image = data_augmentation(image)
  ax = plt.subplot(2, 3, i + 1)
  plt.imshow(augmented_image.numpy()/255)
  plt.axis("off")
```



Aumento de datos mediante tf.image

Flip de izquierda a derecha

```
flipped = tf.image.flip_left_right(image)
visualize(image, flipped)
```



Aumento de datos mediante tf.image

Escala de grises y Ajustar la saturación

```
grayscaled = tf.image.rgb_to_grayscale(image)
visualize(image,  tf.squeeze(grayscaled))
```




```
saturated = tf.image.adjust_saturation(image, 3)
visualize(image, saturated)
```



Aumento de datos mediante tf.image

Ajustar el brillo y Recorte central

```
bright = tf.image.adjust_brightness(image, 0.4)
visualize(image, bright)
```

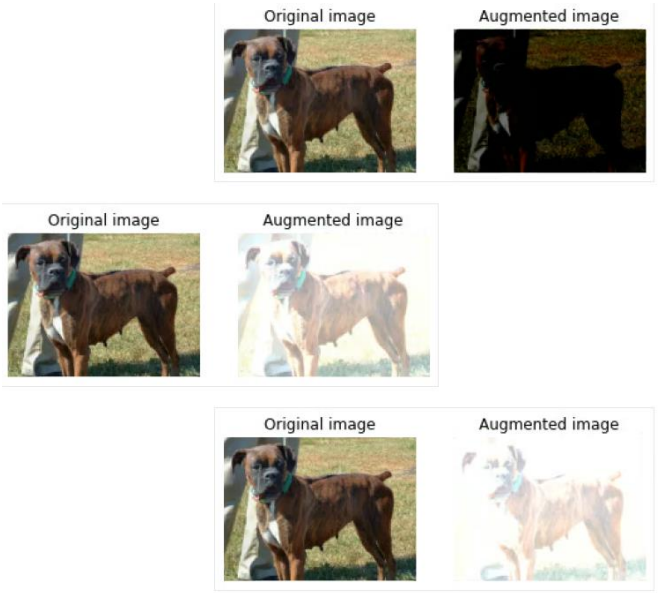



```
cropped = tf.image.central_crop(image,
central_fraction=0.5)
visualize(image, cropped)
```



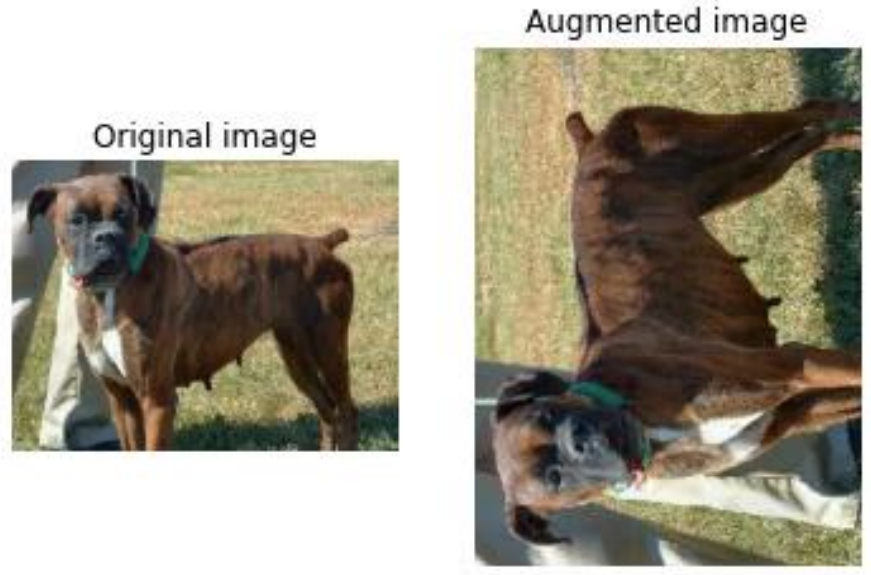
Aumento de datos mediante tf.image

```
for i in range(3):
  seed = (i, 0)  # tuple of size
(2,)
  stateless_random_brightness =
tf.image.stateless_random_brightness
(
      image, max_delta=0.95,
seed=seed)
  visualize(image,
stateless_random_brightness)
```



Rotación de 90 grados y Brillo aleatorio

```
rotated = tf.image.rot90(image)
visualize(image, rotated)
```



• Otras herramientas para el aumento de datos

Pytorch: La transformación de imágenes está disponible en el módulo `torchvision.transforms`. Deforma similar a `Keras`, puedes añadir capas de transformación en `torch.nn.Sequential` o aplicar una función de aumento por separado en el conjunto de datos.

Augmentor: Es un paquete Python para el aumento de imágenes y la generación de imágenes artificiales. Puedes ejecutar Perspective Skewing, Elastic Distortions, Rotating,Shearing, Cropping y Mirroring. Augmentor también incluye funciones básicas de preprocesamiento de imágenes.

Albumentations: Es una herramienta Python rápida y flexible para el aumento de imágenes. Se utiliza ampliamente en competiciones de machine learning, en el sector y en la investigación para mejorar el rendimiento de las redes neuronales convolucionales profundas.

Imgaug: Es una herramienta de código abierto para el aumento de imágenes. Admite una gran variedad de técnicas de aumento, como ruido gaussiano, contraste, nitidez, recorte, affine y flip. Tiene una interfaz estocástica sencilla pero potente, e incluye puntos clave, cuadros delimitadores, mapas de calor y mapas de segmentación.

OpenCV: Es una biblioteca masiva de código abierto para visión artificial, machine learning y procesamiento de imágenes. Se utiliza generalmente en la creación de aplicaciones entiempo real. Puedes utilizar OpenCV para aumentar imágenes y vídeos sin problemas.

Duoc UC®

CERCANÍA. LIDERAZGO. FUTURO.

duoc.cl

7 AÑOS ACREDITADO

Comisión Nacional de Acreditación CNA-Chile

DESDE AGOSTO 2017 HASTA AGOSTO 2024.
DOCENCIA DE PREGRADO. GESTIÓN INSTITUCIONAL. VINCULACIÓN CON EL MEDIO.