

DuocUC® INFORMÁTICA Y TELECOMUNICACIONES

Auditoría de sesgos e implicancias éticas en IA

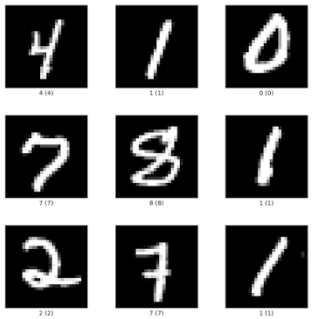
TLY1102

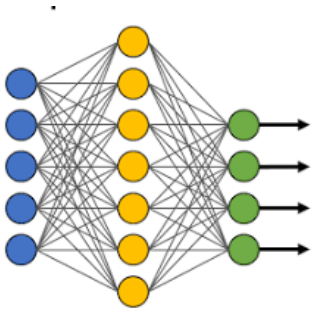
FORMAMOS **PERONAS** PARA UNA **SOCIEDAD** MEJOR

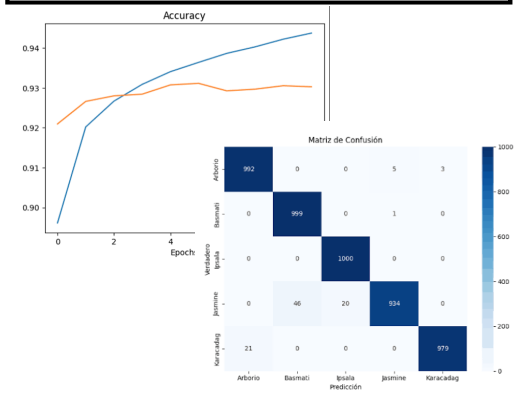
• Introducción

¿Terminó realmente nuestro trabajo?

Dataset → Entrenamiento del modelo → Rendimiento el modelo: Métricas de evaluación





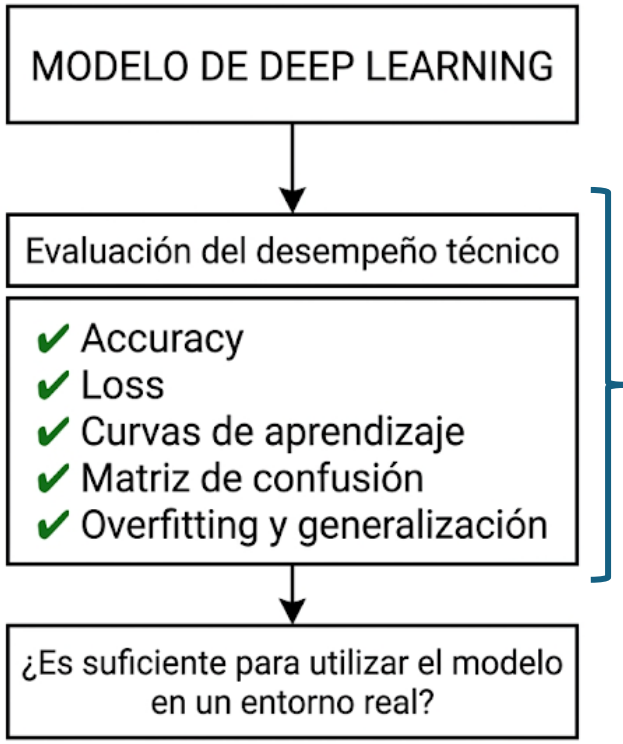


Evaluar el rendimiento no siempre es suficiente

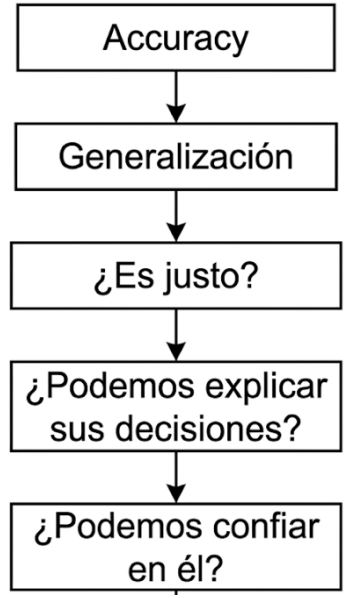
Un modelo puede presentar una **alta Accuracy**, generalizar correctamente y aun así producir decisiones perjudiciales si fue entrenado con datos sesgados o si trata de manera desigual a distintos grupos de personas.

• Introducción

En las unidades anteriores se desarrollaron modelos de aprendizaje profundo y se evaluó su **desempeño técnico** utilizando distintas métricas y herramientas de análisis.



Estas herramientas permiten determinar **qué tan bien predice un modelo**, pero **no indican si las decisiones que toma son apropiadas, equitativas o confiables** cuando el modelo es utilizado en un problema real.



Por esta razón, además del desempeño predictivo, es necesario evaluar aspectos relacionados con la **equidad (Fairness)**, la **transparencia (Explainable AI)** y la **auditoría del modelo**, con el fin de **identificar posibles sesgos antes de su despliegue**.



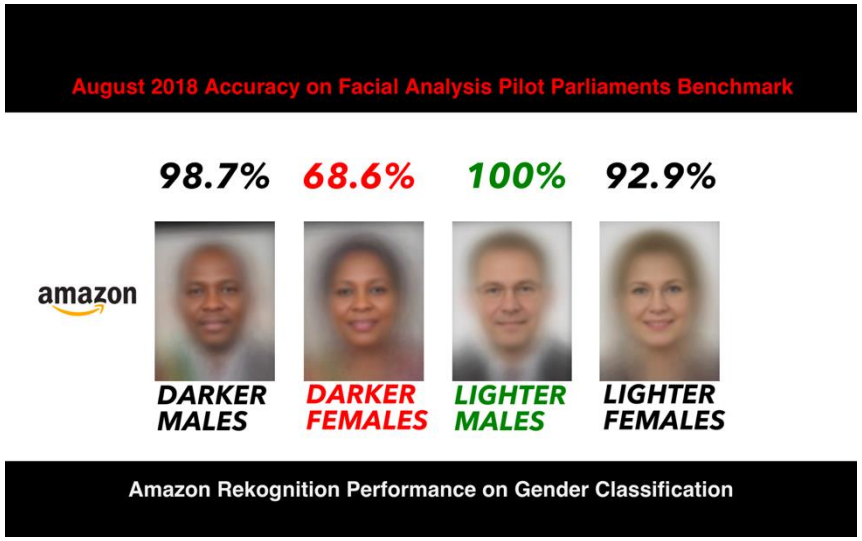
01

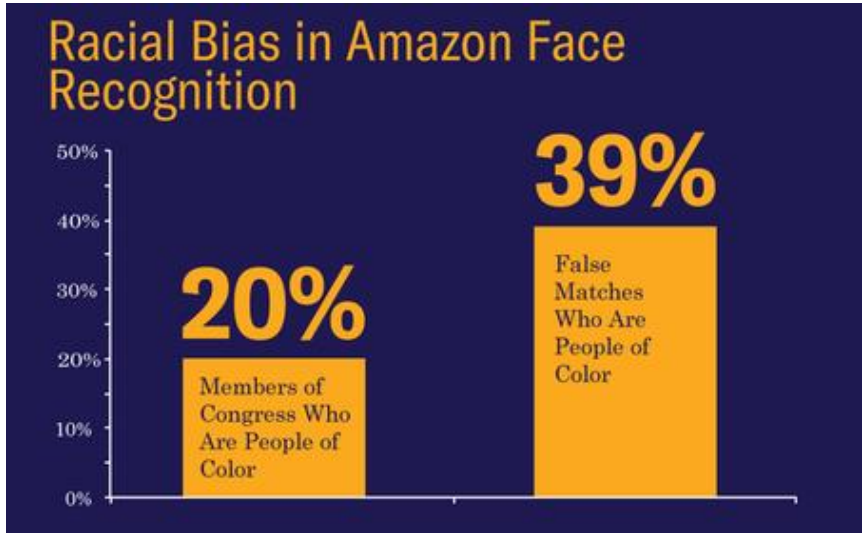
Sesgo

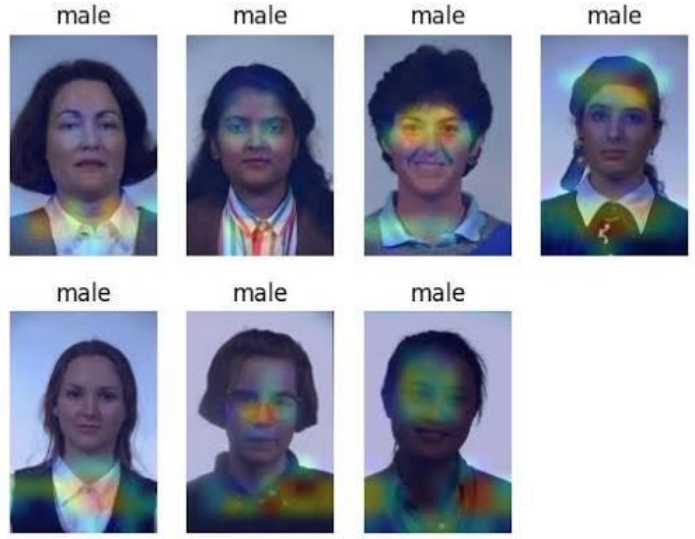
• ¿Puede un modelo con alta accuracy tomar malas decisiones?

Estos casos corresponden a sistemas comerciales de **reconocimiento facial** que alcanzaban una alta precisión global durante su evaluación. Sin embargo, al analizar su desempeño por grupos de personas, se observó que el porcentaje de errores aumentaba significativamente para mujeres y personas de piel más oscura.

Esto demuestra que un modelo puede obtener una **alta Accuracy global** y, aun así, generar resultados injustos para determinados grupos debido a sesgos presentes en los datos de entrenamiento o en el proceso de desarrollo del modelo.



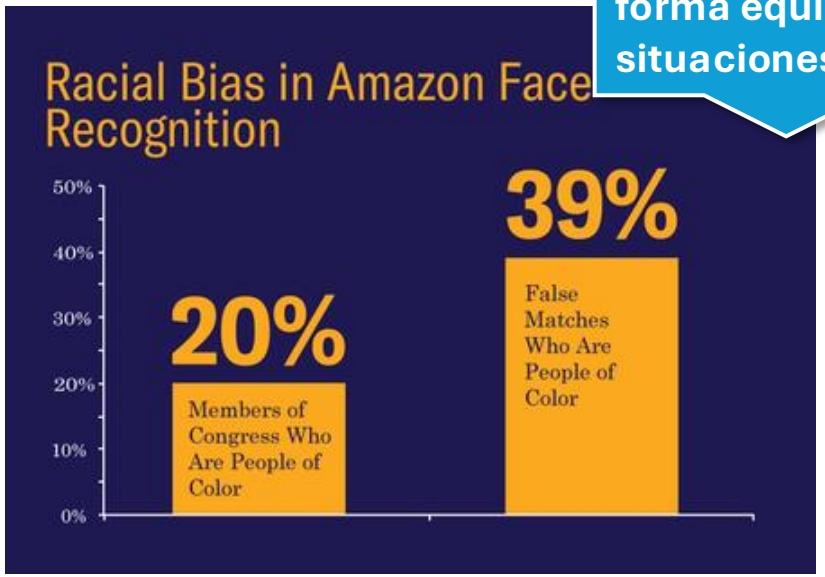




• ¿Qué entendemos por sesgo?

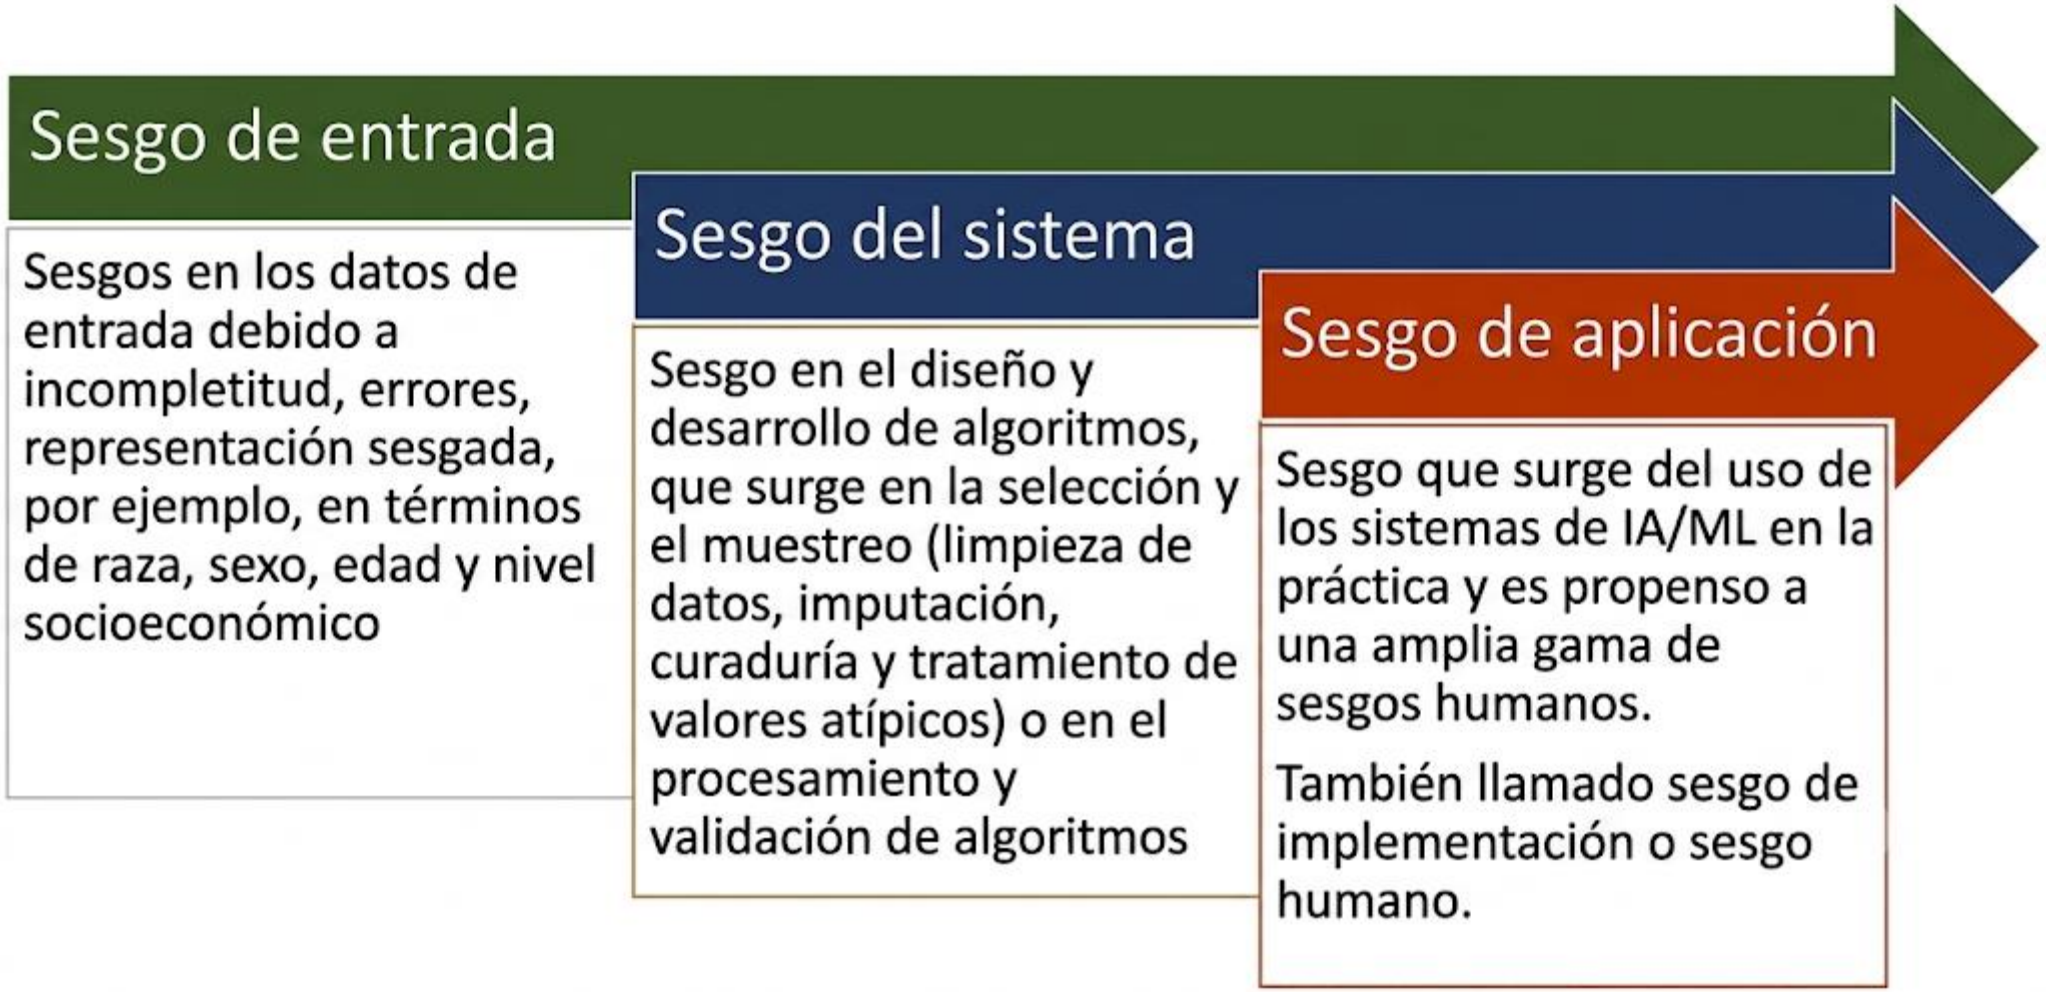
El sesgo no aparece porque el algoritmo "quiera discriminar", sino porque aprende a partir de datos que no representan de forma equilibrada todas las situaciones.

En la diapositiva anterior observamos que un modelo puede obtener una **alta Accuracy global** y, aun así, cometer muchos más errores cuando evalúa determinados grupos de personas.
Esto ocurre porque los modelos **aprenden a partir de los datos con los que fueron entrenados**. Si esos datos contienen **información incompleta, desbalanceada o reflejan prejuicios existentes en el mundo real**, el modelo puede aprender esos mismos patrones y reproducirlos durante la predicción.



Un sesgo (Bias) ocurre cuando un modelo produce **errores o decisiones sistemáticamente desfavorables para determinados grupos**, como consecuencia de problemas presentes en los datos, el algoritmo o el proceso de entrenamiento.

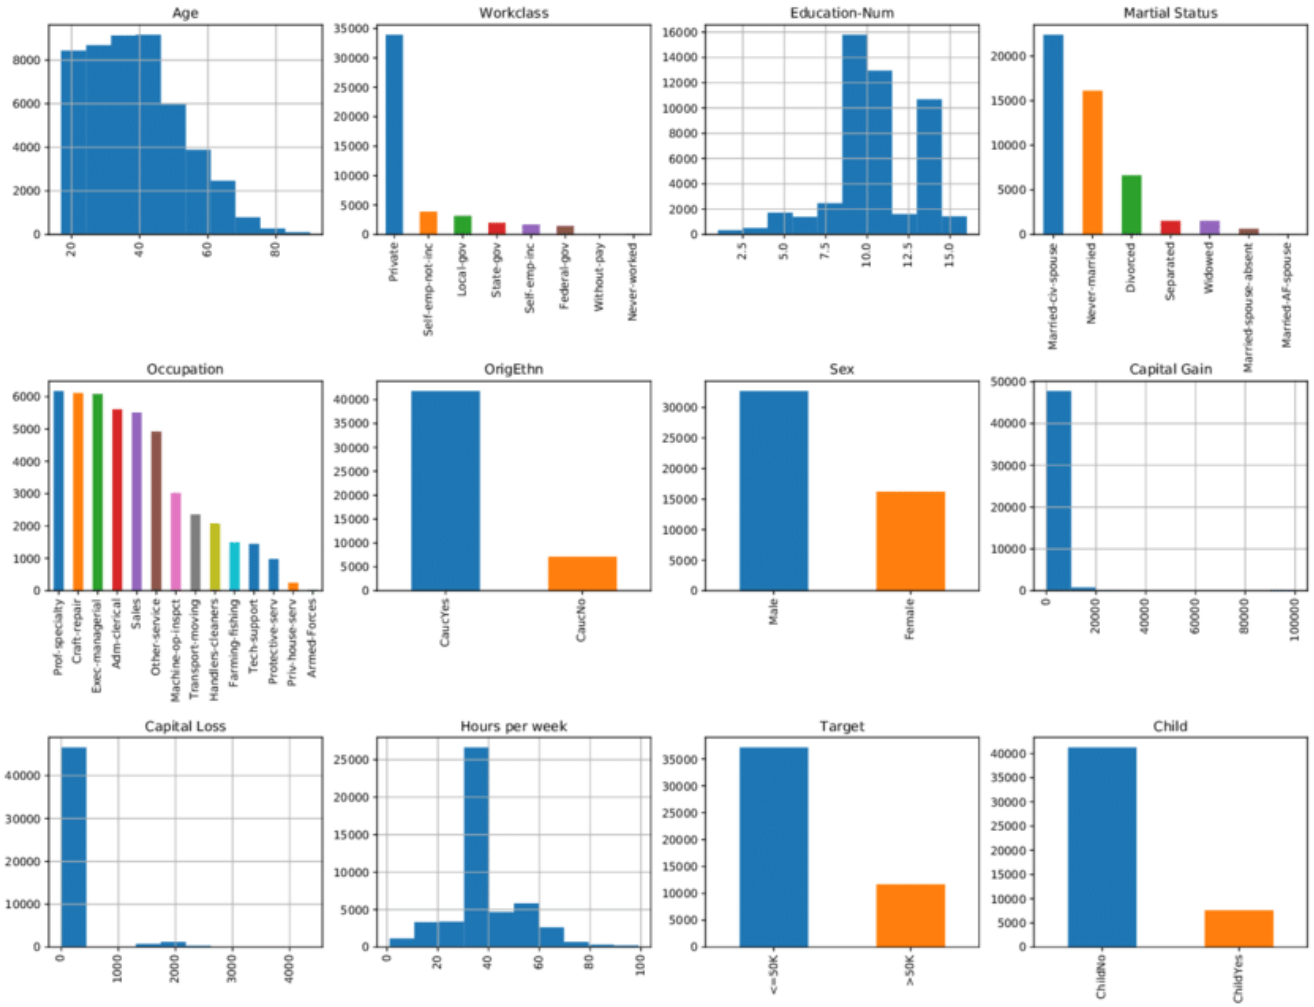
- **Tres fuentes principales de sesgo**



• Sesgo de entrada (Input Bias)

El **sesgo de entrada** se origina cuando los datos utilizados para entrenar un modelo **no representan adecuadamente la realidad**. Esto puede ocurrir porque algunos grupos aparecen con menor frecuencia, existen errores de etiquetado, faltan datos relevantes o la información proviene de una población muy específica.

Cialquier sesgo presente en el conjunto de entrenamiento puede ser aprendido y reproducido durante la predicción.



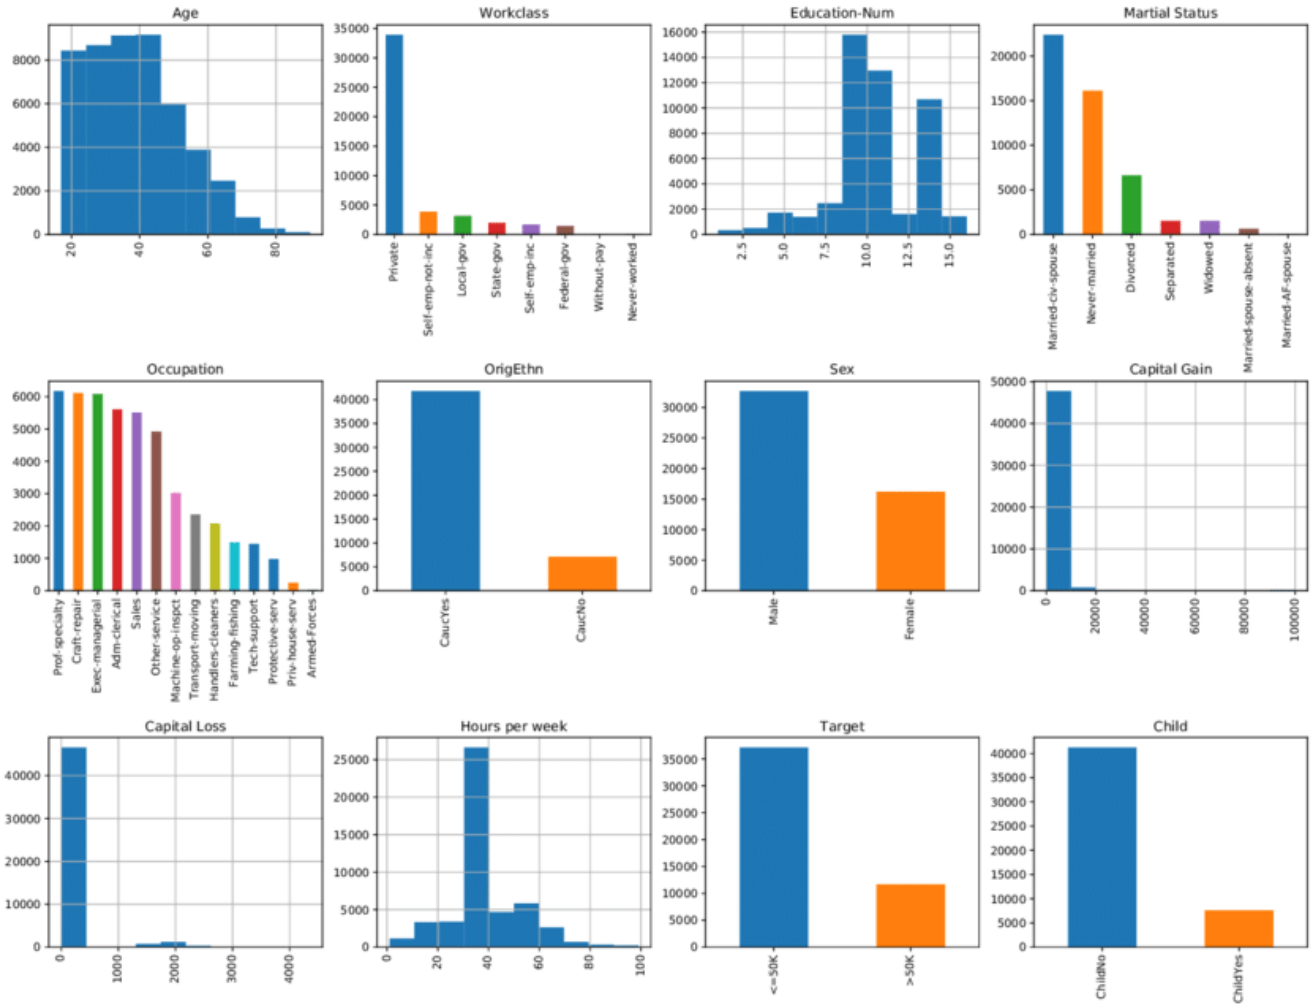
• Sesgo de entrada (Input Bias)

Ejemplos frecuentes:

- **Dataset desbalanceado** (clases minoritarias)
- **Baja representación** de mujeres, adultos mayores o **minorías**
- **Datos recolectados únicamente en una región** o país
- **Etiquetas incorrectas**
- **Valores faltantes en un grupo** específico

¿Cómo **detectarlo**?

- **Distribución** de clases
- Distribución por sexo
- Distribución por raza
- **Valores faltantes**
- **Estadísticos descriptivos**



Adult Income Dataset

El **Adult Income Dataset** (también conocido como **Census Income Dataset**) es un conjunto de datos ampliamente utilizado para tareas de clasificación y auditoría de modelos de Machine Learning.

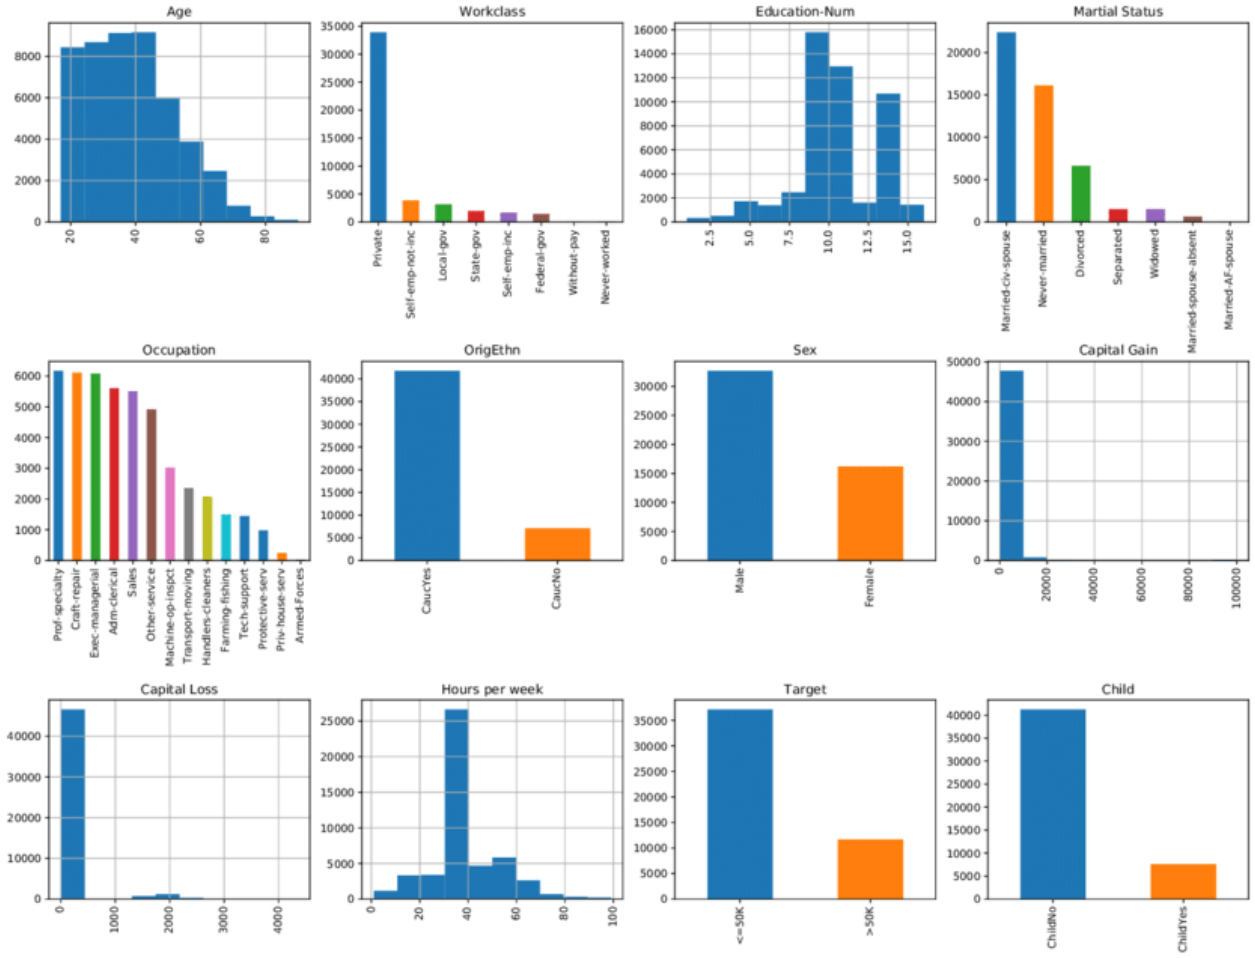
Fue construido a partir de información del **Censo de los Estados Unidos de 1994** y contiene información demográfica, laboral y educacional de miles de personas.

El objetivo consiste en **predecir si una persona obtiene ingresos anuales superiores a USD $50.000**, utilizando únicamente información personal y laboral.

Variables principales

Variable	Descripción
Age	Edad de la persona
Education	Nivel educacional alcanzado
Occupation	Ocupación principal
Workclass	Tipo de empleo
Hours-per-week	Horas trabajadas semanalmente
Marital-status	Estado civil
Sex	Sexo
Race	Grupo racial
Native-country	País de origen
Income	Variable objetivo (>50K o ≤50K)

Adult Income Dataset



Este conjunto de datos incluye **atributos sensibles**, como **sexo** y **raza**, que podrían influir en las decisiones del modelo si existen diferencias importantes en la representación de los datos.

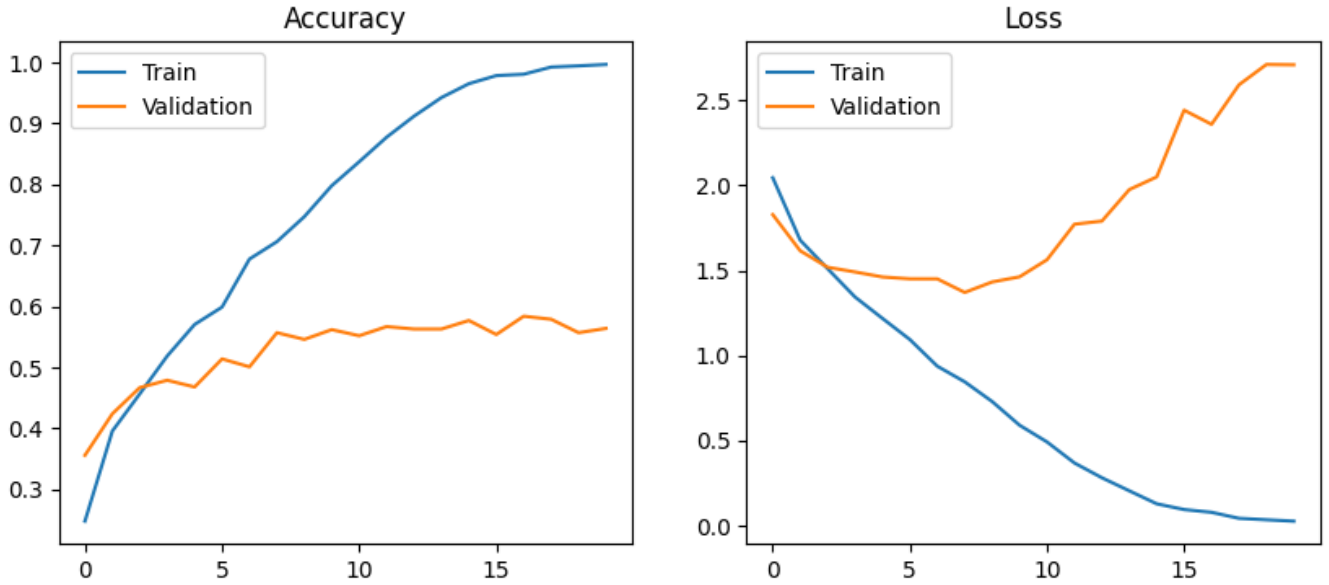
Por esta razón, el Adult Income Dataset se ha convertido en uno de los principales conjuntos de datos utilizados para estudiar:

- Sesgos en los datos (**Input Bias**).
- Equidad (**Fairness**) en modelos predictivos.
- Transparencia y auditoría de sistemas de IA.
- Técnicas para detectar y mitigar discriminación algorítmica.

• Sesgo del sistema (System Bias)

El sesgo del sistema aparece durante el **diseño y desarrollo del modelo**. Aunque los datos sean adecuados, las **decisiones tomadas por el desarrollador pueden favorecer determinados comportamientos del algoritmo**.

Este tipo de sesgo suele estar **relacionado con la selección de variables**, el **preprocesamiento** de los datos, la **arquitectura del modelo**, las **métricas utilizadas** para evaluar el desempeño o la forma en que se **optimizan los parámetros**.



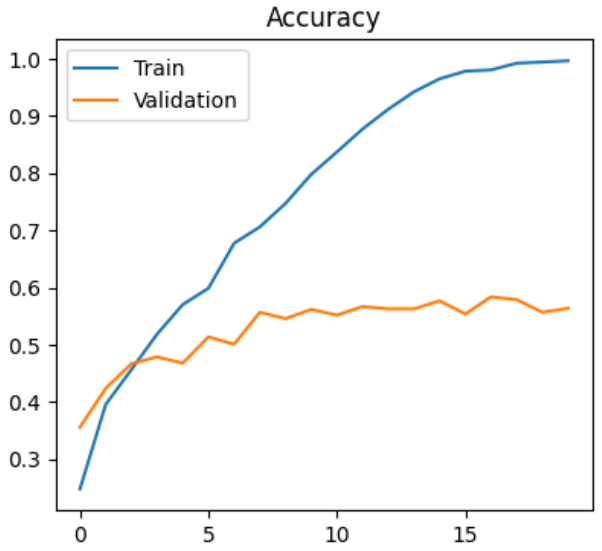
• Sesgo del sistema (System Bias)

Ejemplos

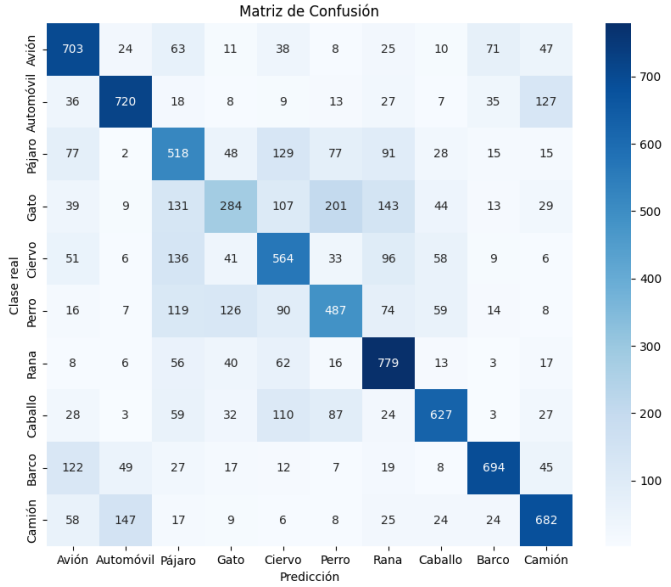
- **Elegir únicamente Accuracy**
- **Eliminar variables importantes**
- **Umbral de decisión inadecuado**
- **Selección incorrecta de características**
- **Modelo demasiado complejo**
- **Modelo entrenado con pocos datos**

¿Cómo detectarlo?

- Curvas de aprendizaje
- Accuracy
- Loss
- Matriz de confusión







• Sesgo de aplicación (Application Bias)

El sesgo de aplicación aparece cuando un modelo se utiliza **en un contexto diferente** para el cual fue diseñado o cuando las decisiones tomadas por el sistema afectan de manera desigual a determinados grupos de personas.

En este caso, **el problema no necesariamente se encuentra en los datos o en el algoritmo, sino en la forma en que el modelo es implementado y utilizado**.

Ejemplos

- Modelo entrenado en Estados Unidos utilizado en Chile
- Reconocimiento facial aplicado a cámaras con distinta iluminación
- Sistema de contratación utilizado como decisión automática
- Modelo médico aplicado a una población distinta

¿Cómo detectarlo?

- Monitoreo continuo
- Evaluación en producción
- Comparación entre grupos
- Retroalimentación de usuarios

• Bias vs Fairness

El sesgo (Bias) es el problema; la equidad (Fairness) es el objetivo.

En Inteligencia Artificial, la **equidad (Fairness)** corresponde al principio de diseñar modelos que tomen decisiones de manera **justa y consistente para todos los grupos de personas**, evitando favorecer o perjudicar sistemáticamente a un grupo debido a atributos sensibles como el sexo, la raza o la edad.

El objetivo no es eliminar todas las diferencias entre las personas, sino **garantizar que el modelo mantenga un desempeño similar para todos los grupos**, evitando discriminaciones injustificadas.



Ejemplo

Grupo	Accuracy
Hombres	**96 %**
Mujeres	**74 %**

Accuracy global: **90 %**

¿El modelo es bueno? **Sí**, presenta una alta Accuracy global.
¿Es un modelo equitativo (Fair)? **No** necesariamente.

Aunque el rendimiento global sea elevado, el modelo comete muchos más errores cuando evalúa solicitudes realizadas por mujeres. Esto indica que el modelo **no ofrece el mismo nivel de desempeño para todos los grupos**, lo que constituye un posible problema de equidad.

• Bias vs Fairness

Un modelo puede ser **preciso**, **generalizar correctamente** y aun así **no ser equitativo**. Por esta razón, la evaluación de un sistema de IA debe considerar tanto métricas tradicionales (Accuracy, Loss, F1-Score) como métricas relacionadas con la **equidad** y el comportamiento del modelo sobre distintos grupos de la población.

¿Cómo podemos saber si un modelo está siendo justo con todos los grupos?

Para responder esta pregunta es necesario **auditar el modelo**, analizando tanto los datos utilizados para entrenarlo como el comportamiento de sus predicciones.





02

Auditar el modelo

Auditoría de modelos de IA

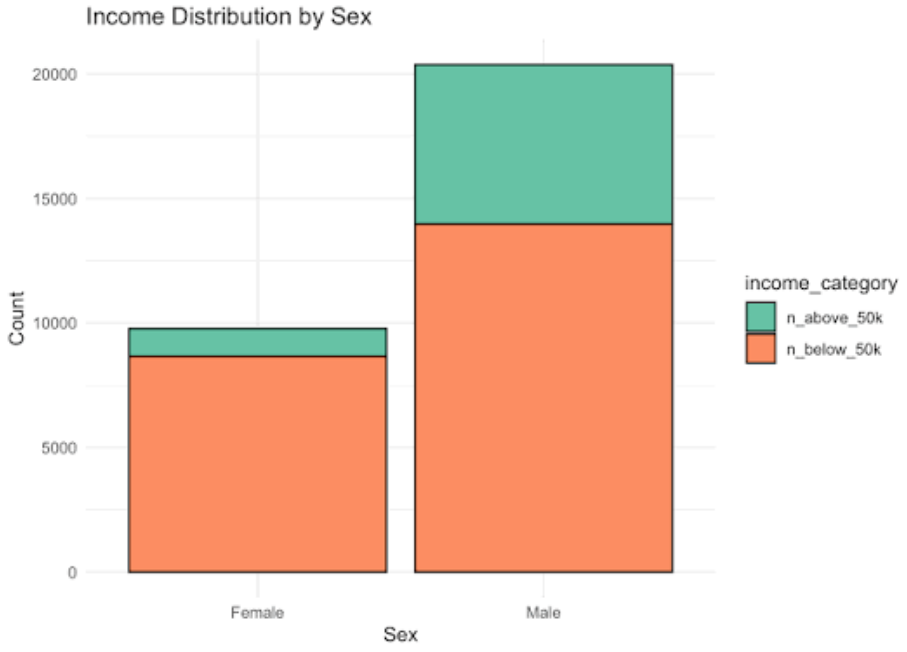
La **auditoría de un modelo de Inteligencia Artificial** consiste en evaluar sistemáticamente los **datos**, el **modelo** y sus **predicciones**, con el objetivo de identificar posibles errores, sesgos o comportamientos que puedan afectar la calidad, equidad o confiabilidad de las decisiones tomadas por el sistema.

A diferencia de la evaluación tradicional, una auditoría **no solo mide qué tan bien predice el modelo**, sino también **cómo toma sus decisiones y sobre quiénes recaen sus errores**.

Objetivos de una auditoría

- Detectar sesgos en los datos de entrenamiento
- Analizar el desempeño del modelo sobre distintos grupos.
- Comprender por qué el modelo toma determinadas decisiones.
- Proponer acciones para reducir los problemas detectados.

Auditoría del Input Bias



Analizar la distribución de los datos.

```
import pandas as pd
df["sex"].value_counts()
df["income"].value_counts()
```

Visualizar

```
import seaborn as sns
sns.countplot(
    data=df,
    x="sex"
)
```

Checklist

¿Hay clases balanceadas?	✓
¿Hay representación suficiente?	✓
¿Existen atributos sensibles?	✓
¿Hay datos faltantes?	✓
¿Quién recolectó estos datos?	✓
¿De qué población provienen?	✓

¿Qué buscamos?

- Clases desbalanceadas
- Grupos poco representados
- Valores faltantes
- Distribuciones muy diferentes

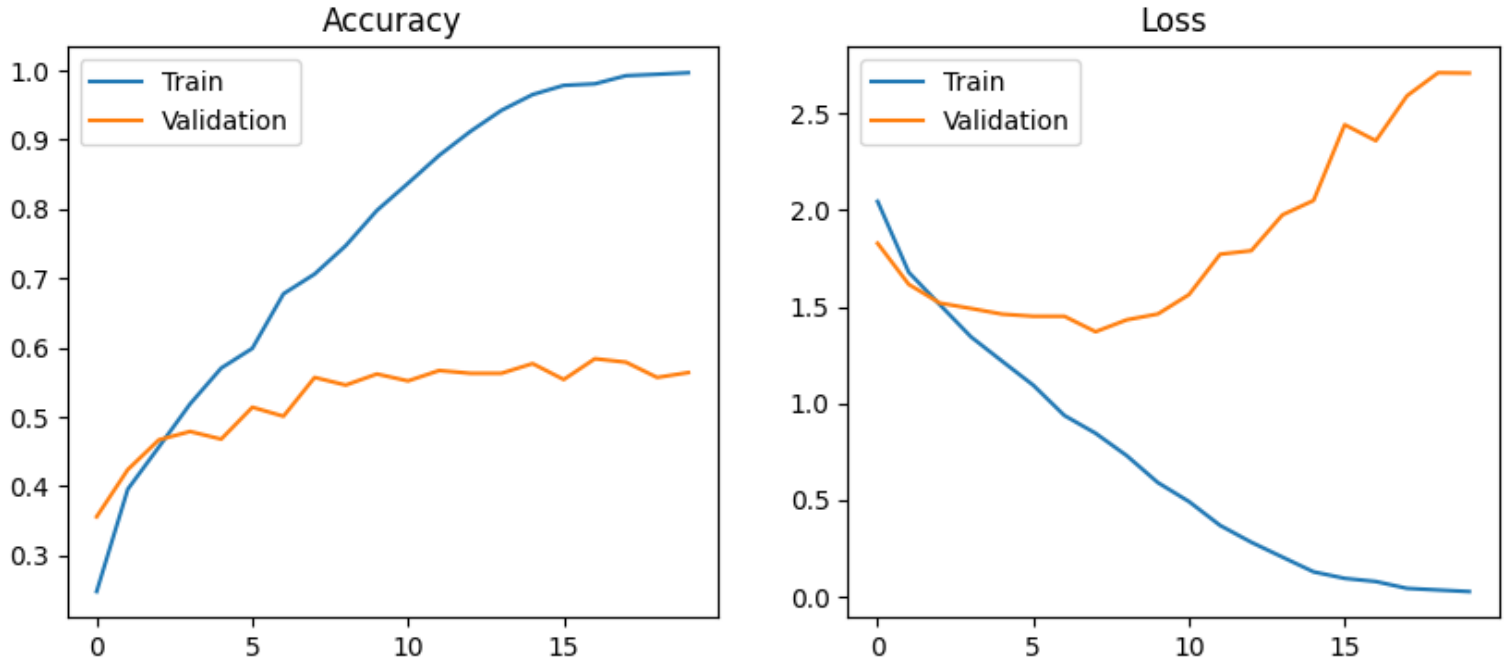
Auditoría del System Bias

¿Qué analizamos?

- Accuracy
- Loss
- Curvas
- Overfitting
- Matriz de confusión
- Precision
- Recall

Un modelo con excelente Accuracy también puede presentar problemas de generalización o favorecer determinadas clases, como vimos en la clase pasada.

```
history.history["accuracy"]
```



Auditoría del Application Bias

Ya no miramos el entrenamiento.

Miramos el despliegue.

¿Qué buscamos?

- El modelo funciona igual en producción.
- Nuevos datos.
- Cambios en la población.
- Errores reportados por usuarios.

Ejemplo.
Un modelo es entrenado con datos provenientes de la problación de EEUU, pero es aplicado en una base de datos compuesta por población Chilena.

En este caso, es muy problable que las distribuciones cambien, según cada población.

En consecuencia el desempeño disminuye.

Resumen de la auditoría

Tipo de sesgo	Evidencia	¿Cómo evaluarlo?	Herramientas
Input Bias	Clases desbalanceadas, atributos sensibles, datos faltantes	Estadísticos descriptivos, histogramas, conteos	Pandas, Matplotlib
System Bias	Overfitting, bajo Recall, clases favorecidas	Curvas, matriz de confusión, Precision, Recall, F1	Scikit-learn
Application Bias	Bajo desempeño en producción, cambios de distribución	Monitoreo, métricas por grupo	Dashboards, auditorías periódicas



03

IA explicable (XAI)

Transparencia Algorítmica

La **Inteligencia Artificial Explicable (Explainable Artificial Intelligence, XAI)** corresponde al conjunto de técnicas que permiten comprender **por qué un modelo de Inteligencia Artificial tomó una determinada decisión**.

Mientras que métricas como **Accuracy** o **F1-Score** indican **qué tan bien predice un modelo**, las técnicas de XAI permiten responder preguntas como:

- ¿Qué variables fueron más importantes para realizar la predicción?
- ¿Qué regiones de una imagen utilizó la red neuronal?
- ¿Qué características influyeron positiva o negativamente en la decisión?

Por esta razón, XAI constituye una herramienta fundamental durante la **auditoría de modelos**, ya que permite detectar posibles sesgos y aumentar la transparencia del sistema.

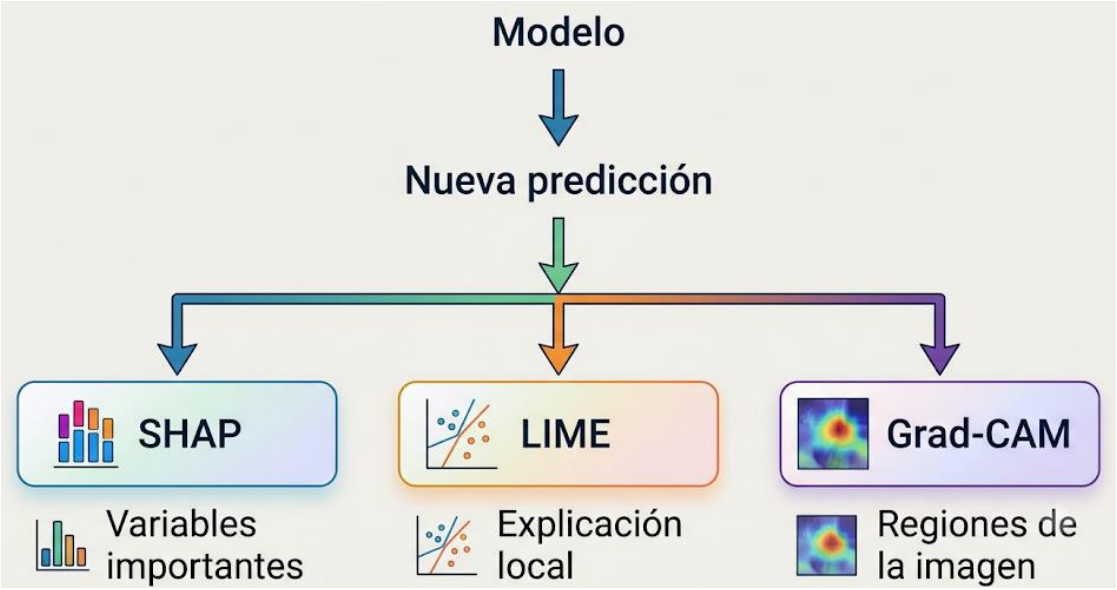
Técnicas de IA explicable

XAI no mejora la Accuracy

Las técnicas de XAI **no aumentan directamente el rendimiento del modelo**.

Su objetivo consiste en:

- Comprender cómo toma decisiones el modelo.
- Detectar posibles sesgos.
- Facilitar la auditoría.
- Generar confianza en sistemas de IA.
- Apoyar la toma de decisiones en aplicaciones críticas.



Técnica	Tipo de datos	¿Qué explica?	Ejemplo
SHAP	Datos tabulares	Importancia de cada variable en la predicción	Adult Income
LIME	Tabulares, imágenes y texto	Explicación local de una predicción específica	Crédito bancario
Grad-CAM	Imágenes (CNN)	Regiones de la imagen que activaron la decisión	Clasificación de imágenes

SHAP (SHapley Additive exPlanations)

Su nombre proviene de los **valores de Shapley**, un concepto de la teoría de juegos utilizado para repartir de forma justa la contribución de cada participante. En Inteligencia Artificial, SHAP adapta esta idea para estimar **cuánto contribuye cada variable a una predicción realizada por un modelo**.

SHAP permite responder preguntas como:

- ¿Qué variables fueron más importantes para esta predicción?
- ¿Qué variables aumentaron la probabilidad de una clase?
- ¿Qué variables disminuyeron esa probabilidad?
- Es una técnica ampliamente utilizada para explicar modelos entrenados sobre **datos tabulares**, como el dataset **Adult Income**.

Ejemplo

Supongamos que un modelo predice que una persona tendrá ingresos superiores a $50.000. SHAP podría indicar:

Variable	Contribución
Education	+0.32
Hours-per-week	+0.21
Age	+0.10
Sex	-0.18

Interpretación:

*La educación y las horas trabajadas favorecieron la predicción, mientras que la variable **Sex** redujo la probabilidad. Si un atributo sensible aparece con una influencia excesiva, podría ser una señal de un posible sesgo.*

SHAP (SHapley Additive exPlanations)

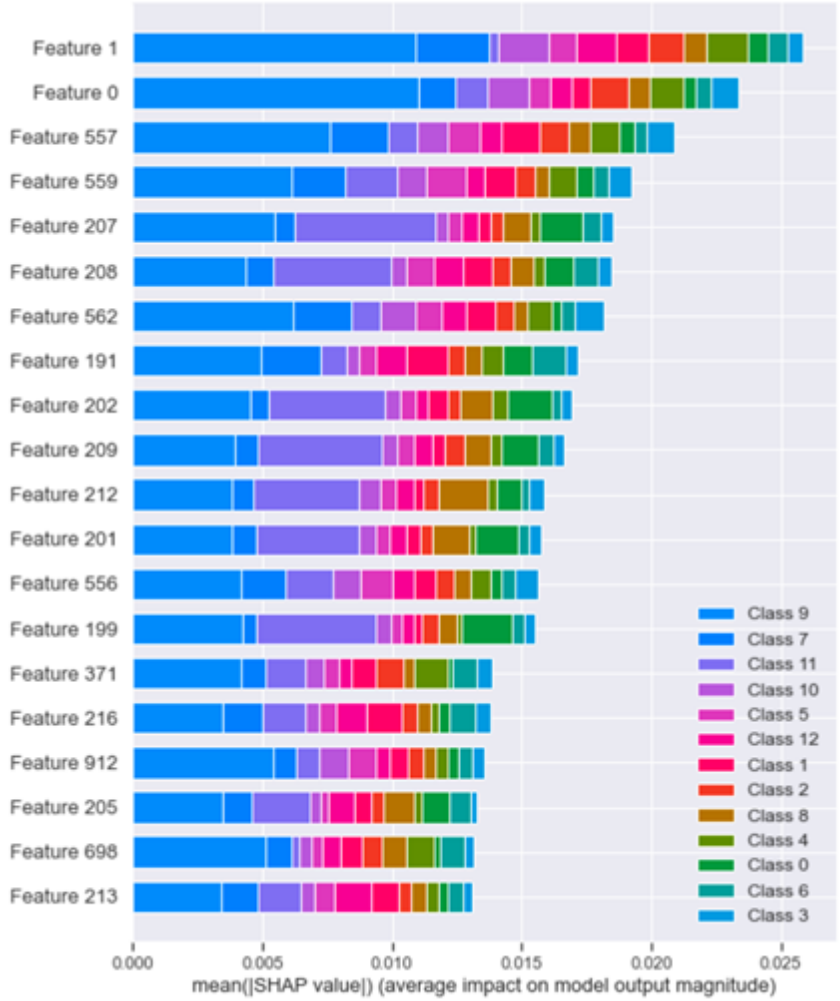
Implementación en Python

```
import shap

# Crear el explicador
explainer = shap.Explainer(model, X_train)

# Calcular valores SHAP
shap_values = explainer(X_test)

# Visualizar importancia de variables
shap.plots.bar(shap_values)
```



LIME (Local Interpretable Model-agnostic Explanations)

LIME corresponde a las siglas de **Local Interpretable Model-agnostic Explanations**.

- **Local**: explica una única predicción.
- **Interpretable**: genera una explicación fácil de comprender.
- **Model-agnostic**: puede utilizarse con prácticamente cualquier modelo de Machine Learning o Deep Learning.

Mientras SHAP puede analizar el comportamiento global del modelo, **LIME explica una única decisión**.

Funcionamiento

LIME modifica ligeramente los datos alrededor de una observación y observa cómo cambia la predicción del modelo. A partir de esas variaciones construye un modelo simple que aproxima el comportamiento del clasificador únicamente en esa región.

LIME (Local Interpretable Model-agnostic Explanations)

Implementación en Python

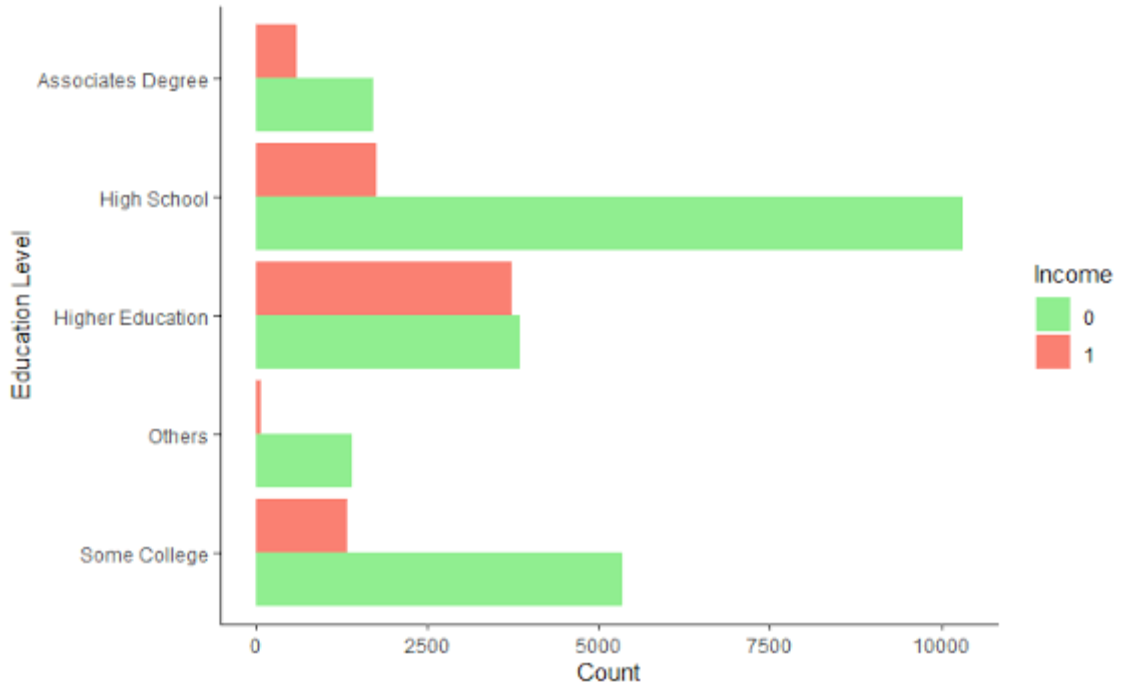
Para datos tabulares:

```
from lime.lime_tabular import
LimeTabularExplainer

explainer = LimeTabularExplainer(
    X_train,
    feature_names=feature_names,
    class_names=["<=50K", ">50K"],
    mode="classification"
)

exp = explainer.explain_instance(
    X_test[0],
    model.predict_proba
)

exp.show_in_notebook()
```



Beneficios de la IA explicable

Utilizar la IA con confianza y seguridad

Permite **generar confianza en la IA de producción** y poner en marcha los modelos con rapidez. Asimismo, garantiza la **interpretabilidad y explicabilidad** de dichos modelos, al tiempo que **simplifica el proceso de evaluación**, aumentando la transparencia y la trazabilidad de todo el sistema.

Aceleración de los resultados de la IA

Permite **monitorear y gestionar sistemáticamente los modelos** para optimizar los resultados empresariales, evaluando y mejorando continuamente su rendimiento. Asimismo, ayuda a afinar los esfuerzos de desarrollo basados en una evaluación constante.

Mitigar el riesgo y el coste de la gobernanza del modelo

Ayuda a mantener los modelos de IA **explicables y transparentes**, lo que facilita la gestión de los requisitos normativos, de conformidad y de riesgo. De este modo, se minimiza la sobrecarga de la inspección manual, se evitan errores costosos y se **mitiga el riesgo de sesgos no deseados**.

Auditoría	XAI
¿Existe un sesgo?	¿Qué produjo ese sesgo?
¿Qué grupo presenta más errores?	¿Qué variables influyeron?
¿El modelo falla?	¿Por qué falla?



03

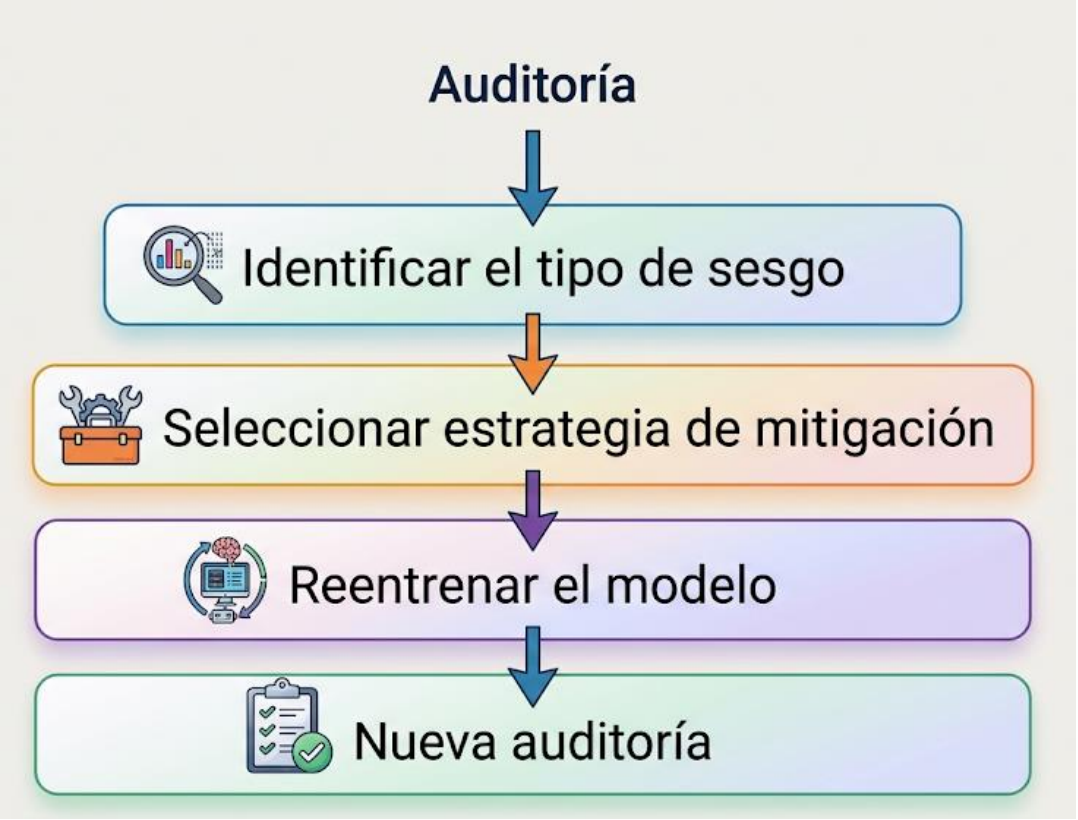
Mitigación del sesgo

• Mitigación de sesgos en modelos de IA

Una vez identificado un posible sesgo mediante el proceso de auditoría, el siguiente paso consiste en **reducir su impacto** antes de desplegar el modelo.

La mitigación de sesgos corresponde al conjunto de estrategias utilizadas para mejorar la equidad, robustez y confiabilidad de un sistema de Inteligencia Artificial.

Es importante destacar que **no existe una solución universal**. La estrategia dependerá del origen del sesgo identificado durante la auditoría.



Mitigar un sesgo no consiste únicamente en modificar el modelo. En muchos casos el problema se encuentra en los datos o en la forma en que el sistema será utilizado.

• Mitigación del Input Bias

El conjunto de entrenamiento no representa adecuadamente la población real.

Ejemplos:

- Clases desbalanceadas.
- Baja representación de un grupo.
- Datos faltantes.
- Etiquetas incorrectas.

Estrategias de mitigación:

1. **Balanceo de Clases:** Cuando una clase posee muchos menos ejemplos que otra.
2. **Data Augmentation:** Incrementar artificialmente la muestra de entrenamiento.
3. **Recolección de nuevos datos**

Si un grupo está poco representado, la solución más robusta consiste en i**ncorporar nuevos ejemplos reales.**

- Upsampling: Consiste en **aumentar artificialmente** la cantidad de ejemplos de la clase minoritaria.

Ejemplo con Python

```
from sklearn.utils import resample

minority = resample(
    minority,
    replace=True,
    n_samples=len(majority),
    random_state=42
)
```

- Downsampling: Reducir ejemplos de la clase mayoritaria.

```
majority = resample(
    majority,
    replace=False,
    n_samples=len(minority),
    random_state=42
)
```

• Mitigación del System Bias

Problema
El sesgo se produce durante el diseño del modelo.

Ejemplos.
- Overfitting.
- Arquitectura inadecuada.
- Métrica incorrecta.
- Variables irrelevantes.



Estrategias

1. Regularización
- Dropout
- EarlyStopping
- Batch Normalization

2. Selección de variables
- Eliminar atributos irrelevantes.
- Reducir variables redundantes.

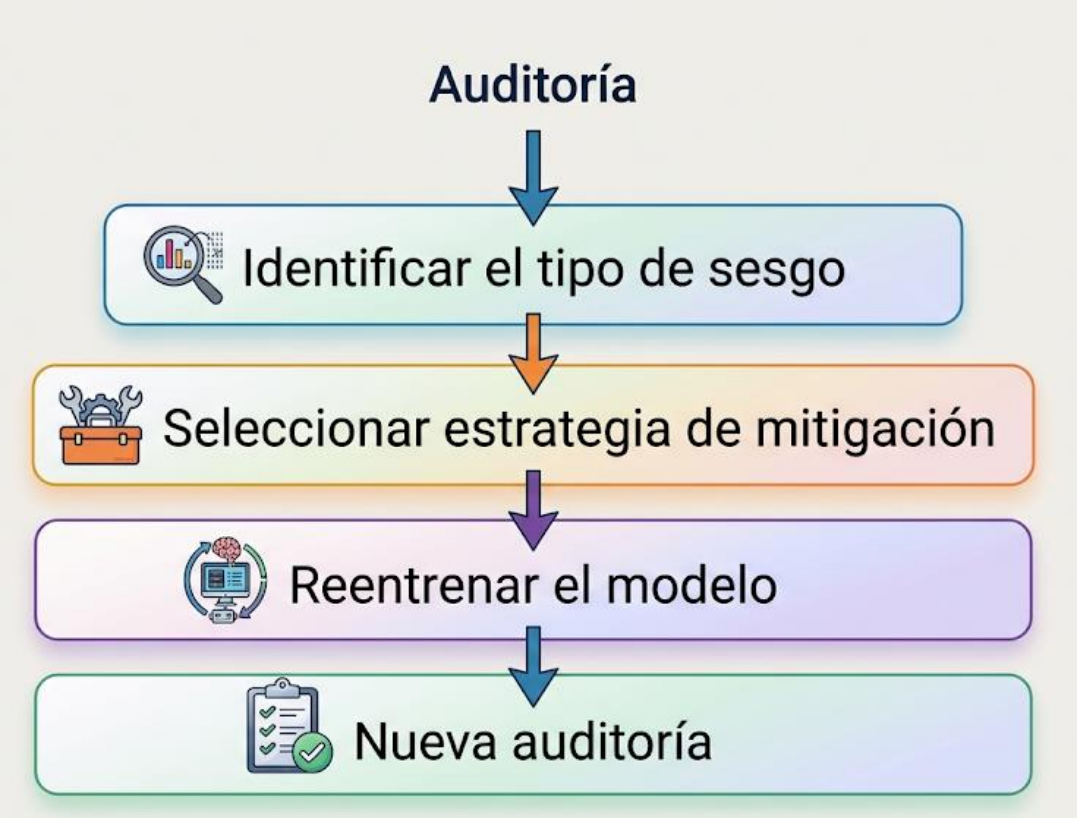
3. Validación adecuada
- Cross Validation
- Hold-out
- Conjuntos independientes

4. Métricas apropiadas
No evaluar únicamente Accuracy.

• Mitigación del Application Bias

Problema
El modelo funciona correctamente durante el entrenamiento, pero no durante su utilización.

Estrategias
- Reentrenamiento periódico.
- Incorporar nuevos datos.
- Monitoreo continuo.
- Supervisión humana.
- Explainable AI.
- Auditorías periódicas.



Resumen de estrategias de mitigación

No existe un modelo completamente libre de sesgos.

Por ello, el desarrollo responsable de sistemas de IA requiere un proceso continuo de evaluación y mejora.

Tipo de sesgo	Problemas frecuentes	Estrategias de mitigación
Input Bias	Clases desbalanceadas, representación desigual, datos faltantes	Upsampling, Downsampling, Data Augmentation, nuevos datos, limpieza del dataset
System Bias	Overfitting, mala selección de variables, arquitectura inadecuada	Regularización, validación cruzada, selección de variables, métricas apropiadas
Application Bias	Cambios en la población, uso fuera del contexto original	Monitoreo, reentrenamiento, supervisión humana, auditorías periódicas, XAI

Un modelo de Inteligencia Artificial confiable no es aquel que obtiene únicamente una alta Accuracy.
Es aquel que además:

- **Generaliza correctamente.**
- **Toma decisiones consistentes.**
- **Es transparente.**
- **Puede ser auditado.**
- **Reduce al mínimo posible los sesgos presentes en los datos y en el proceso de desarrollo.**

ESCUELA DE INFORMÁTICA Y TELECOMUNICACIONES

Adult Income Dataset

En la siguiente actividad asumiremos el rol de auditores de un sistema de Inteligencia Artificial. Antes de entrenar cualquier modelo, analizaremos este dataset para identificar posibles sesgos, evaluaremos cómo afectan al proceso de aprendizaje y propondremos estrategias para mitigarlos.

¿Qué analizaremos en este laboratorio?

Durante la actividad práctica responderemos las siguientes preguntas:

- ¿Existen diferencias en la representación de hombres y mujeres?
- ¿Cómo se distribuyen los ingresos según el sexo o la raza?
- ¿El modelo presenta un desempeño similar para todos los grupos?
- ¿Qué evidencia permite afirmar que existe (o no) un sesgo?
- ¿Qué medidas podrían implementarse para reducir ese sesgo?

¿Por qué este dataset es ideal para estudiar sesgos?

A diferencia de datasets como **MNIST** o **CIFAR-10**, donde el objetivo consiste únicamente en reconocer imágenes, el Adult Income Dataset aborda un problema relacionado con **personas y decisiones socioeconómicas**.
Cuando un modelo utiliza atributos sensibles como el sexo o la raza para predecir ingresos, es fundamental verificar que sus decisiones sean **equitativas, transparentes y libres de discriminación**. Por ello, este dataset es ampliamente utilizado en investigación para evaluar algoritmos de **Fairness**, **Explainable AI (XAI)** y **auditoría de modelos**.

DuocUC®

Duoc UC®

CERCANÍA. LIDERAZGO. FUTURO.

duoc.cl

7 AÑOS ACREDITADO

Comisión Nacional de Acreditación CNA-Chile

DESDE AGOSTO 2017 HASTA AGOSTO 2024.
DOCENCIA DE PREGRADO. GESTIÓN INSTITUCIONAL. VINCULACIÓN CON EL MEDIO.