

DuocUC® INFORMÁTICA Y TELECOMUNICACIONES

Pipeline integrado

TLY1102

FORMAMOS PERONAS PARA UNA SOCIEDAD MEJOR

• Integrando todas las etapas del desarrollo de un modelo de Deep Learning

Un pipeline complete para la implementación previa debería verse así....

Durante las unidades anteriores aprendimos diferentes herramientas para construir, entrenar y evaluar modelos de Deep Learning.

Sin embargo, cada una fue estudiada de forma independiente. En un proyecto real estas etapas forman parte de un único proceso denominado **Pipeline de Machine Learning**.



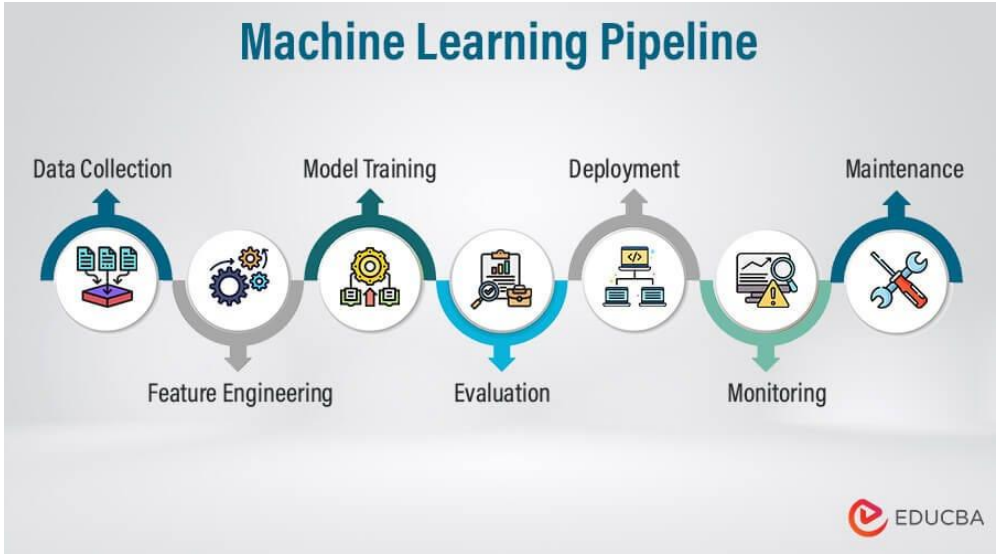
¿Qué es un Pipeline?

Un **Pipeline** es una secuencia organizada y reproducible de etapas que permiten transformar datos crudos en un modelo de Inteligencia Artificial listo para ser utilizado.

Cada etapa recibe la salida de la etapa anterior, permitiendo automatizar el flujo completo de trabajo y facilitando la reproducibilidad, el mantenimiento y la mejora continua del sistema.

Características

- Reproducible
- Modular
- Escalable
- Fácil de mantener
- Fácil de reutilizar



¿Por qué utilizar un Pipeline?

Sin Pipeline	Con Pipeline
Código desordenado y difícil de seguir.	**Código organizado** y modular.
Variables repetidas que pueden inducir a errores.	**Fácil reutilización** de componentes y pasos.
Difícil de mantener a largo plazo.	**Comparación objetiva** de métricas y resultados.
Difícil comparar experimentos de forma consistente.	**Mayor trazabilidad** de los datos y modelos.
Mucho código duplicado (redundancia).	**Mejor trabajo colaborativo** en equipo.

Un pipeline permite repetir un experimento exactamente bajo las mismas condiciones.

• Pipeline general de Machine Learning



Pipeline general de Machine Learning

Carga de datos
Todo pipeline comienza obteniendo la información que utilizará el modelo. (Pandas, TensorFlow Datasets)

Puede provenir de:
- CSV
- Excel
- Base de datos
- API
- Imágenes
- Audio



Preprocesamiento
Antes del entrenamiento los datos deben prepararse.

Actividades
- Limpieza
- Valores faltantes
- Codificación
- Escalamiento
- División Train/Test
- Data Augmentation

Pipeline general de Machine Learning

Construcción del modelo
Elegir correctamente la arquitectura depende del tipo de problema y del tipo de datos disponibles.

MLP	CNN
Datos tabulares	Imágenes
Dense	Convolución
Flatten obligatorio	No
Aprende relaciones globales	Aprende patrones espaciales



Entrenamiento
Durante esta etapa el modelo ajusta sus parámetros mediante descenso del gradiente.

Variables importantes.
- Epochs
- Batch Size
- Learning Rate
- Optimizer

• Pipeline general de Machine Learning

Regularización

Problema	Técnica
Alta varianza	Dropout
Entrenamiento excesivo	Early Stopping
Pesos excesivamente grandes	Regularización L2
Distribución inestable de activaciones	Batch Normalization
Inicialización inadecuada de los pesos	Inicialización He
Cantidad limitada de datos	Data Augmentation



Evaluación

Tipo de evaluación	Herramientas
Seguimiento del entrenamiento	Loss, Accuracy, Curvas de aprendizaje
Desempeño del clasificador	Accuracy, Precision, Recall, F1-Score
Análisis de errores	Matriz de Confusión
Capacidad discriminativa	Curva ROC y AUC
Auditoría e interpretación	SHAP, LIME, Grad-CAM

Pipeline general de Machine Learning

Auditoría
La auditoría permite determinar si el modelo produce decisiones confiables y equitativas antes de su despliegue.

Puede provenir de:
- Bias (sesgo)
- Fairness
- XAI
- Mitigacion



Optimización
Ajuste de hiperparámetros
- Learning Rate
- Batch Size
- Arquitectura
- Callbacks
- Validación Cruzada (Cross Validation)

• Pipeline en código

Definimos funciones para cada etapa, así Podemos reutilizar Código, evitar redundancias y mantener el orden.

```
def cargar_datos():

def preprocesar():

def construir_modelo():

def entrenar():

def evaluar():

def auditar():

def guardar_modelo():
```

```
def main():

   datos = cargar_datos()

   datos = preprocesar(datos)

   modelo = construir_modelo()

   history = entrenar(modelo)

   evaluar(modelo)

   auditar(modelo)

   guardar_modelo()
```

Buenas practices

- Modularizar funciones.
- No duplicar código.
- Guardar modelos.
- Registrar experimentos.
- Documentar resultados.
- Fijar semillas aleatorias.
- Utilizar notebooks limpios.
- Utilizar comentarios
- Mantener una estructura clara de carpetas.

Del Pipeline al Proyecto Final

- El proyecto final no consiste únicamente en entrenar un modelo.
- Consiste en diseñar un pipeline completo.

El objetivo no es escribir más código. El objetivo es aprender a organizar correctamente un proyecto de Deep Learning para que sea reproducible, escalable y fácil de mantener.

Hoy construiremos un Pipeline capaz de

1. cargar datos
2. preprocesar
3. construir el modelo
4. entrenar
5. regularizar
6. evaluar
7. auditar
8. guardar resultados

Duoc UC®

CERCANÍA. LIDERAZGO. FUTURO.

duoc.cl

7 AÑOS ACREDITADO

Comisión Nacional de Acreditación CNA-Chile

DESDE AGOSTO 2017 HASTA AGOSTO 2024.
DOCENCIA DE PREGRADO. GESTIÓN INSTITUCIONAL. VINCULACIÓN CON EL MEDIO.